杰伊·阿拉马尔 (/)

一次一个概念地可视化机器学习。

阅读我们的书《动手大型语言模型 (https://www.LLM-book.com)》，并在LinkedIn (https://www.linkedin.com/in/jalammar/)、Bluesky (https://bsky.app/profile/jayalammar.bsky.social)、Substack (https://newsletter.languagemodels.co/)、X (https://x.com/JayAlammar)、YouTube (https://www.youtube.com/channel/UCmOwsoHty5PrmE-3QhUBfPQ)上关注我

神经机器翻译模型可视化（Seq2seq模型的力学与注意力）

翻译：中文（简体）、 (https://blog.csdn.net/qq_41664845/article/details/84245520)法 (https://lbourdois.github.io/blog/nlp/Seq2seq-et-attention/)语、日语 (https://tips-memo.com/translation-jayalmmar-attention)、韩语 (https://nlpinkorean.github.io/visualizing-neural-machine-translation-mechanics-of-seq2seq-models-with-attention/)、波斯语 (http://dml.qom.ac.ir/2021/10/03/visualizing-a-neural-machine-translation-model/)、俄 (https://habr.com/ru/post/486158/)语、土耳其语 (https://medium.com/@SenemAktas/n%C3%B6ral-makine-%C3%A7eviri-modelini-g%C3%B6rselle%C5%9Ftirme-seq2seq-modelinin-attention-mekanizmas%C4%B1-b12581b5a1df)、乌兹别克 (https://murodbek.substack.com/p/neyron-mashinaviy-tarjima-modellarini)语 观察：麻省理工学院深度学习 (https://youtu.be/53YvP6gdD7U?t=335)最新讲座引用本文

5月25日更新：新增图形（RNN动画、单词嵌入图）、颜色编码，并对最终的注意力示例进行了详细阐释。

注：下面的动画是视频。触摸或悬停（如果你用鼠标）可以获得游戏控制，这样需要时可以暂停。

序列对序列模型是一种深度学习模型，在机器翻译、文本摘要和图片说明等任务中取得了巨大成功。谷歌翻译于2016年底开始采用 (https://blog.google/products/translate/found-translation-more-accurate-fluent-sentences-google-translate/)此类模型。这些模型在两篇开创性论文中得到了解释

（Sutskever等，2014 (https://papers.nips.cc/paper/5346-sequence-to-sequence-learning-with-neural-networks.pdf);Cho等，2014 (http://emnlp2014.org/papers/pdf/EMNLP2014179.pdf)）。

不过我发现，要足够理解模型并实现它，需要拆解一系列层层叠加的概念。我觉得这些想法如果用视觉表达会更容易理解。这正是我在这篇文章中想要表达的。你需要先有深度学习的基础知识才能完成这篇文章。我希望它能成为阅读上述论文（以及文章后面链接的关注论文）的有用辅助。

序列到序列模型是一种模型，它将一系列项目（单词、字母、图像特征等）处理成一系列。等等）并输出另一组项目。训练好的模型工作方式如下：

0:00 / 0:08

在神经机器翻译中，序列是一系列单词，依次处理。输出同样是一系列单词：

0:00 / 0:08

深入了解引擎盖

模型底层由编码器和解码器组成。

编码器处理输入序列中的每个项，将捕获的信息编译成一个向量（称为上下文）。处理完整个输入序列后，编码器将上下文发送给解码器，解码器开始逐项输出序列。

0:00 / 0:09

机器翻译也是如此。

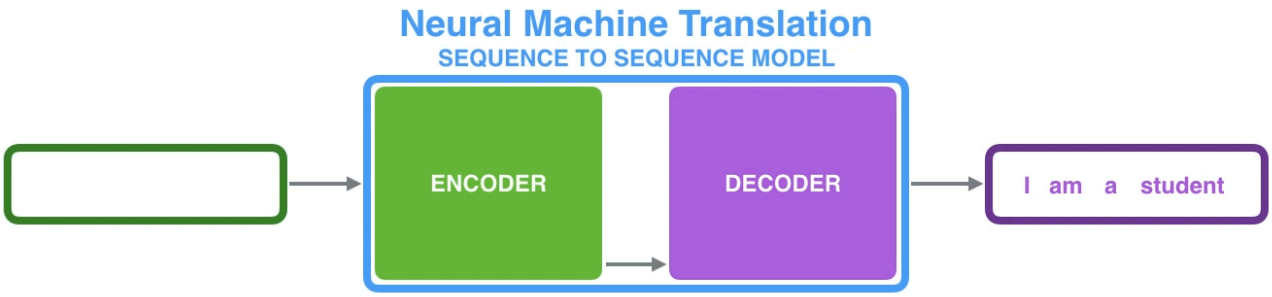

在机器翻译中，上下文是一个向量（基本上是数字数组）。编码器和解码器通常都是循环神经网络（请务必阅读Luis Serrano的《A friendly introduction to Recurrent Neural Networks》 (https://www.youtube.com/watch?v=UNmqTiOnRfg)了解RNNs）。

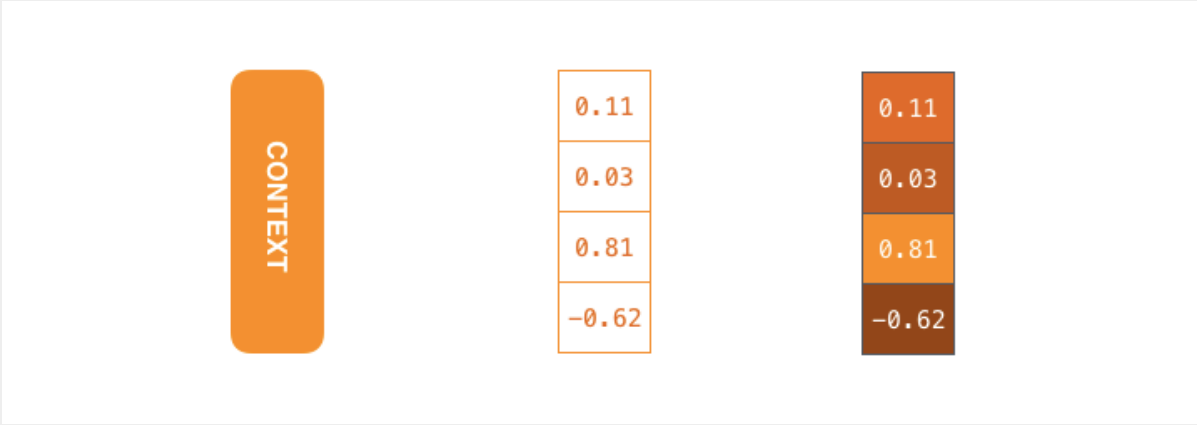

上下文是float向量。本文后面我们将通过为数值较高的单元格分配更亮的颜色来可视化向量的颜色。

你可以在设置模型时设置上下文矢量的大小。它基本上是编码器RNN中隐藏单元的数量。这些可视化显示的矢量大小为4，但在现实应用中，上下文矢量大小如256、512或1024。

设计上，RNN在每个时间步接收两个输入：一个输入（编码器中，输入一个词来自输入句子），另一个是隐藏状态。然而，这个词需要用向量来表示。要将单词转换为向量，我们采用了一类称为“单词嵌入 (https://machinelearningmastery.com/what-are-word-embeddings/)”算法的方法。这些将词语转化为向量空间，捕捉词语的大量含义和语义信息（例如国王 - 男性 + 女性 = 皇后 (http://p.migdal.pl/2017/01/06/king-man-woman-queen-why.html)）。

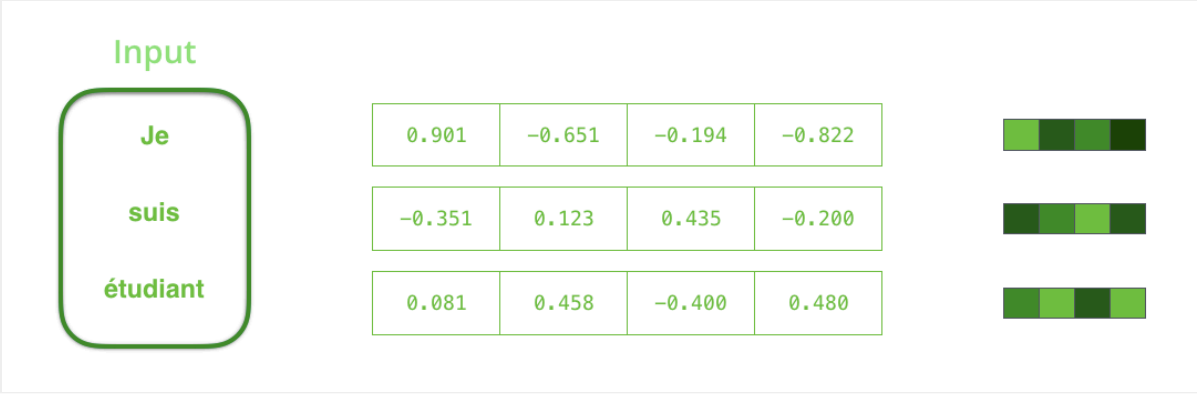

我们需要先把输入词转化为向量，然后再处理它们。这种变换是通过词嵌入 (https://en.wikipedia.org/wiki/Word_embedding)算法完成的。我们可以使用预训练 (http://ahogrammer.com/2017/01/20/the-list-of-pretrained-word-embeddings/)嵌入，也可以在数据集上训练自己的嵌入。嵌入大小为200或300的向量是典型的，我们展示的是大小为4的向量以简化。

既然我们已经介绍了主要的向量/张量，让我们回顾一下RNN的机制，并建立一种描述这些模型的视觉语言：

0:09 / 0:13

下一步RNN采用第二个输入向量和隐藏状态#1，生成该时间步的输出。在文章后面，我们将用类似的动画来描述神经机器翻译模型中的向量。

在下面的可视化中，编码器或解码器的每个脉冲都是RNN处理输入并在该时间步产生输出的脉冲。由于编码器和解码器都是RNN，每当其中一个RNN进行处理时，它会根据输入和之前的输入更新隐藏状态。

让我们看看编码器的隐藏状态。注意最后一个隐藏状态实际上是我们传递给解码器的上下文。

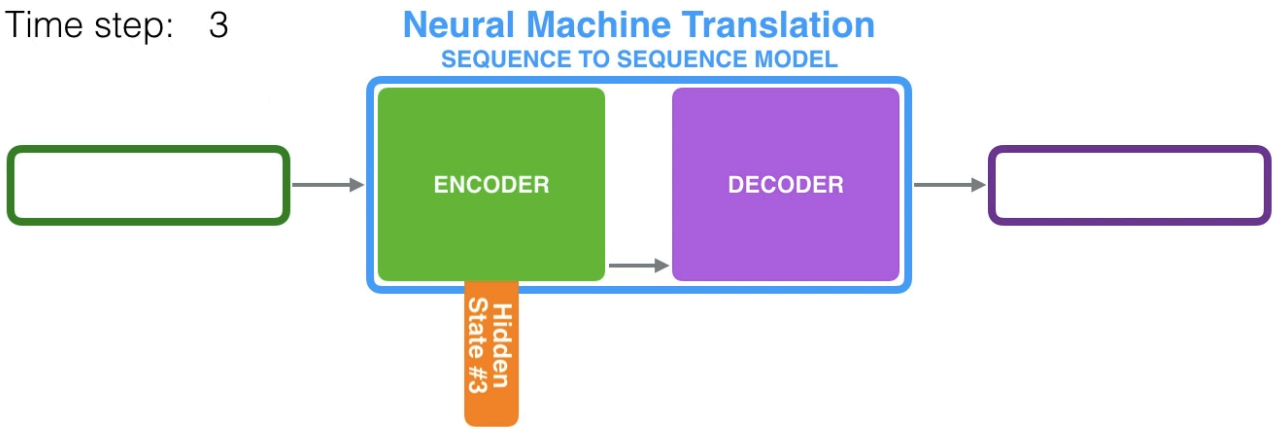

解码器还会保持一个隐藏状态，从一个时间步传递到下一个时间步。我们只是没有在这张图中进行可视化，因为目前我们关注的是模型的主要部分。

现在让我们看看另一种可视化序列到序列模型的方法。这个动画会让你更容易理解描述这些模型的静态图形。这被称为“展开视图”，即我们不展示唯一的解码器，而是每个时间步的解码器副本。这样我们可以查看每个时间步的输入和输出。

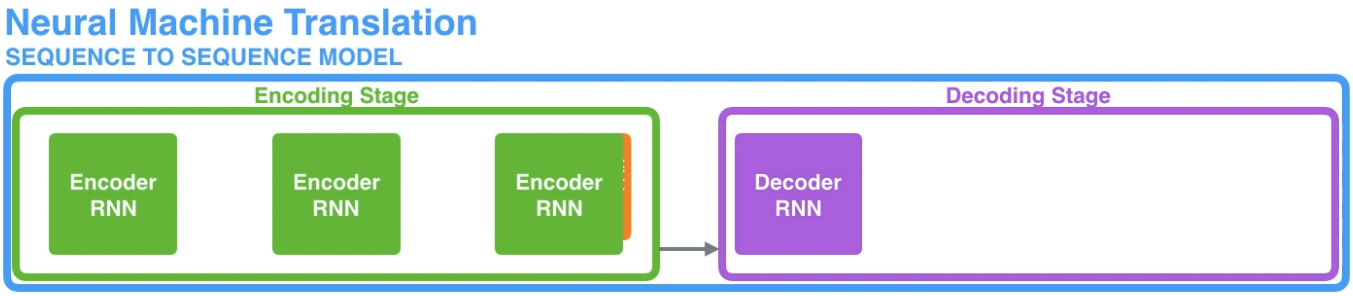

现在让我们注意听听

上下文向量成为这类模型的瓶颈。这让模型在处理长句子时变得很有挑战性。Bahdanau 等人，2014 (https://arxiv.org/abs/1409.0473) 年和 Luong 等人，2015 (https://arxiv.org/abs/1508.04025) 年提出了解决方案。这些论文引入并完善了一种名为“注意力”的技术，极大提升了机器翻译系统的质量。注意力使模型能够根据需要专注于输入序列中的相关部分。

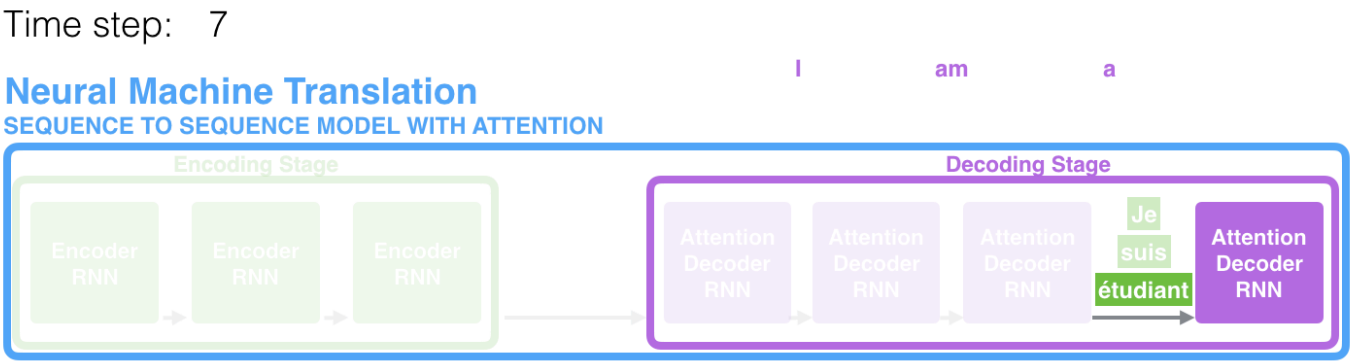

在第7步，注意机制使解码器能够先聚焦于单词“étudiant”(法语中的“学生”)，然后生成英文翻译。这种能够放大输入序列中相关部分信号的能力，使注意力模型比无注意力模型产生更好的结果。

让我们继续在这种高度抽象层次上研究注意力模型。注意力模型与经典的序列对序列模型有两个主要区别：

首先，编码器会传递更多数据给解码器。编码器不传递编码阶段的最后一个隐藏状态，而是将*所有*隐藏状态传递给解码器：

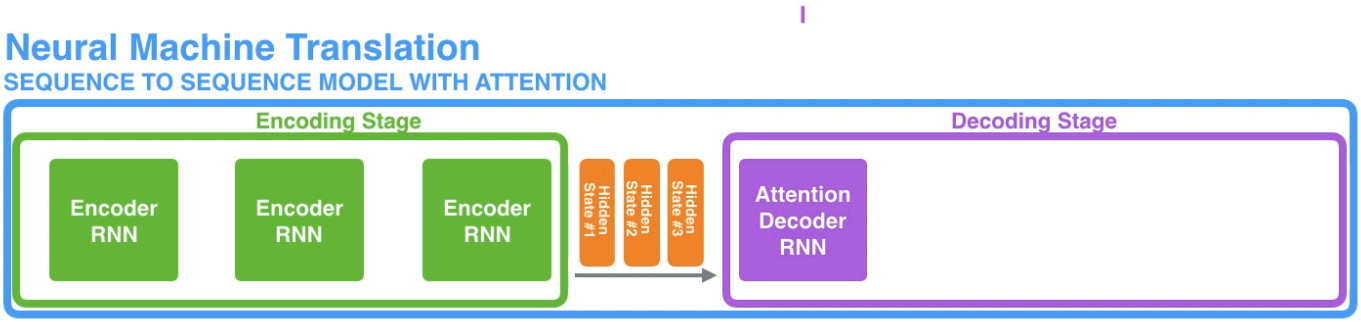

其次，注意力解码器在输出前会多做一步。为了聚焦与该解码时间步相关输入的部分，解码器会做以下操作：

1. 看看它接收到的编码器隐藏状态集合——每个编码器隐藏状态最能与输入句子中的某个词相关
2. 给每个隐藏状态打分（暂且不考虑评分方式）
3. 将每个隐藏状态乘以软最高分，从而用高分放大隐藏状态，低分则淹没隐藏状态

0:17 / 0:18

这个评分练习在解码器侧的每个时间步骤都进行。

现在让我们用下面的可视化方式将整个过程整合起来，看看注意力过程是如何运作的：

1. 注意解码器RNN会嵌入<END>令牌，并处于初始解码器隐藏状态。
2. RNN处理输入，产生输出和新的隐藏态向量（h4）。输出被丢弃。
3. 注意步骤：我们使用编码器的隐藏态和 h4 向量计算该时间步的上下文向量（C4）。
4. 我们将h4和C4连接成一个向量。
5. 我们将该向量传递给一个前馈神经网络（与模型共同训练）。
6. 前馈神经网络的输出表示该时间步的输出字。
7. 重复下一次的步骤

0:30 / 0:31

这是另一种看待我们在每个解码步骤中关注输入句子哪部分的方法：

0:09 / 0:10

需要注意的是，模型并不是无意识地把输出处的第一个词和输入的第一个词对齐。它实际上是在训练阶段学会了如何对齐该语言对中的词（我们例子中的法语和英语）。这种机制有多精确的一个例子可以从上面提到的注意力论文中看：

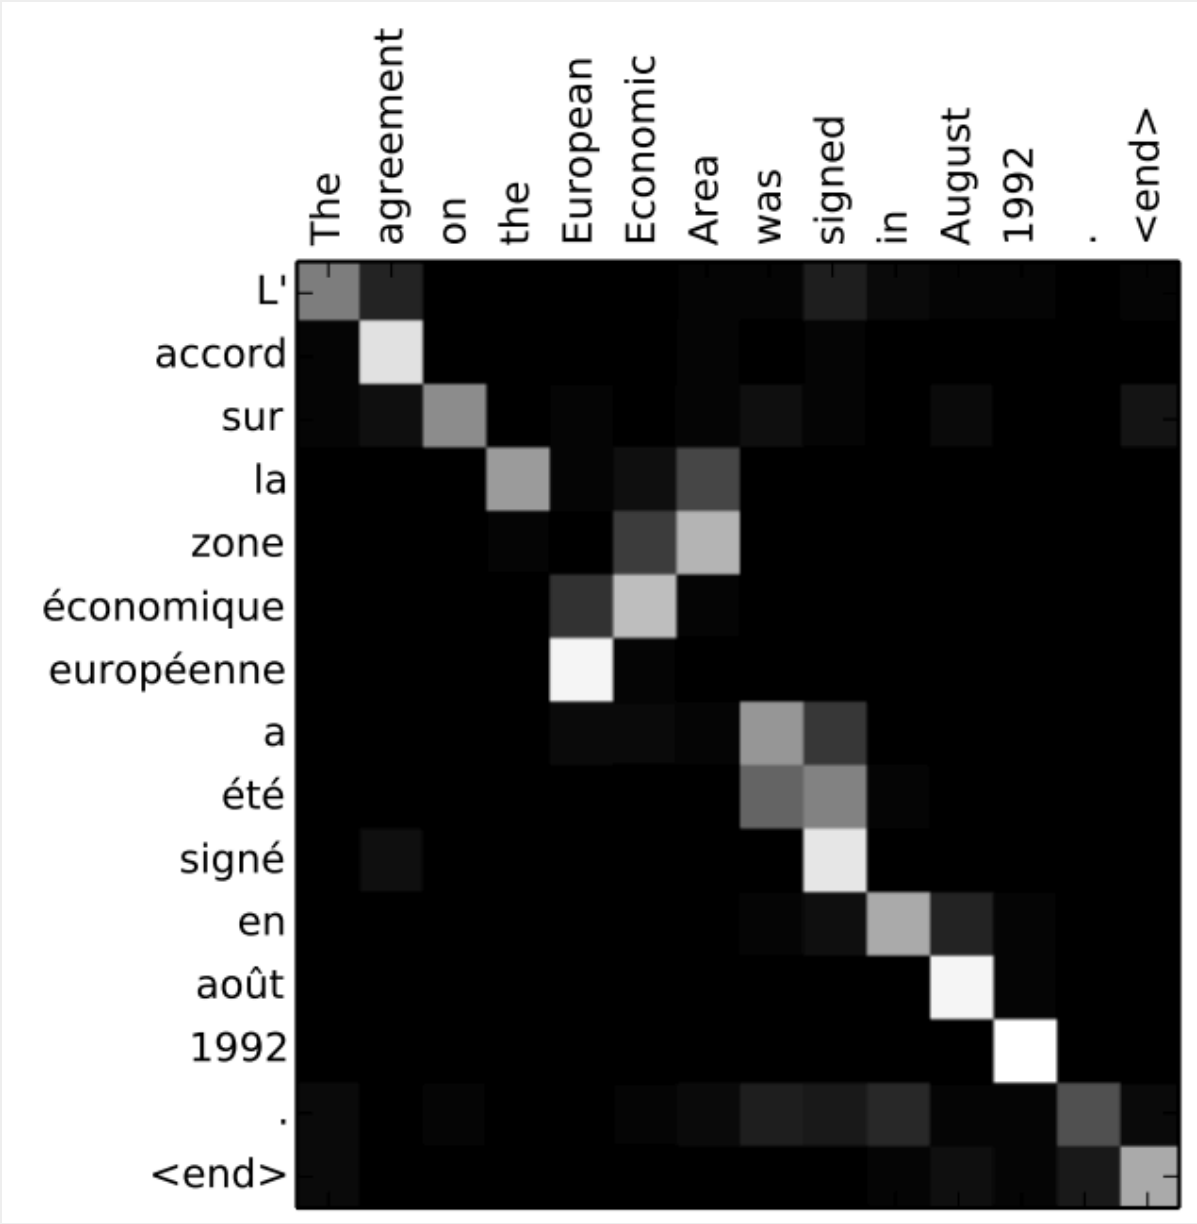

你可以看到模型在输出“欧洲经济区”时是如何正确关注的。在法语中，这些词的顺序与英语相反（“européenne économique zone”）。句子中每隔一个词的顺序也差不多。

如果你觉得自己准备好学习实现，务必查看TensorFlow的神经机器翻译（seq2seq）教程 (https://github.com/tensorflow/nmt)。

希望你觉得这些对你有帮助。这些视觉图是Udacity自然语言处理纳米学位项目 (https://www.udacity.com/course/natural-language-processing-nanodegree--nd892)中注意力课程的早期版本。课程中会有更多细节，包括讨论应用以及介绍一些较新的注意力方法，比如《注意力就是你所需要 (https://arxiv.org/abs/1706.03762)的》中的变换器模型。

请观看NLP纳米学位项目 (https://www.udacity.com/course/natural-language-processing-nanodegree--nd892)的预告片：

Natural Language Processing Nanodegree Program

我还为Udacity的机器学习纳米学位项目 (https://www.udacity.com/course/machine-learning-engineer-nanodegree--nd009t)制作了几节课程。我创建的课程涵盖了无监督学习，以及一本关于通过协作过滤推荐电影的Jupyter笔记本。

我很希望听听你们的任何反馈。请通过@JayAlammmar (https://twitter.com/JayAlammar)联系我。
撰写于2018年5月9日

Language Models & Co.

Large language models, their internals, and applications.

By Jay Alammar • Over 32,000 subscribers

Type your email... Subscribe

By subscribing you agree to Substack's Terms of Use, our Privacy Policy and our Information collection notice

substack

(http://creativecommons.org/licenses/by-nc-sa/4.0/)
本作品采用知识共享署名-非商业性-相同方式共享4.0国际许可 (http://creativecommons.org/licenses/by-nc-sa/4.0/)协议授权。

归因示例：
Alammar， J（2018）。图解变形金刚【博客文章】。取自 https://jalammar.github.io/illustrated-transformer/ (https://jalammar.github.io/illustrated-transformer/)

注：如果你翻译了任何帖子，请告诉我，我会把你的翻译链接到原帖。我的邮箱在关于页面 (/about)。

(https://github.com/jalammar) (https://www.linkedin.com/in/jalammar) (https://www.twitter.com/jayalammar)